

Apprentissage fédéré pour le diagnostic médical

Comparaison Centralisé vs Fédéré Dataset Heart Disease UCI

KHOUAJA Ahmed

Master 2 MIASHS
Encadrante : BENARBA Nawel

Février 2026

Objectif

Comparer l'entraînement centralisé à l'entraînement fédéré sur *Heart Disease UCI* et analyser l'impact de l'hétérogénéité.

Message principal :

- **IID $\approx$ Baseline** : Performance conservée.
- **Non-IID** : Dégradation de la performance et augmentation de la variabilité.

→ *Présentation des diagnostics, causes et extensions (FedProx, Bruit, Équité).*

Le Split Stratifié :

- Train : 177
- Validation : 60
- **Test : 60**

Point Critique

Avec 60 exemples de test, l'accuracy évolue par pas de :

$$\frac{1}{60} \approx 0.0167 \quad (1.67\%)$$

Conséquence :

- Les faibles écarts ne sont pas des preuves absolues.
- Nécessité de confirmer par d'autres métriques (ROC-AUC, Brier) et par le multi-seeds.

Protocole d'évaluation : Éviter le biais test

Principe : Le test est utilisé une seule fois pour mesurer la généralisation.

- **Baseline (Centralisée) :**
 - Sélection par *Early Stopping* sur la validation.
- **Fédéré (FL) :**
 - À chaque round : mesure de la validation.
 - Sélection du round "*Best Val*".
- **Stabilité :**
 - Exécutions multi-seeds (moyenne et dispersion).

Note : Comparaison stricte intra-protocole.

Choix : Simplicité et stabilité sur petit dataset.

Architecture MLP :

- Entrée : 13 variables.
- Couches : $13 \rightarrow 64 \rightarrow 32 \rightarrow 2$.
- **Régularisation** : BatchNorm + Dropout.

Optimisation :

- SGD (Momentum 0.9).
- **Gradient Clipping** (norme max 1.0).

Pourquoi le clipping ?

Essentiel en FL non-IID pour éviter l'explosion des mises à jour locales instables.

Résultats de référence : Baseline vs FL

Synthèse principale (Moyenne $\pm$ écart-type sur 5 seeds)

Méthode	Accuracy	ROC-AUC
Baseline (Centralisée)	0.7833 ± 0.0558	0.8897 ± 0.0343
FedAvg IID	0.7933 ± 0.0416	0.8958
FedAvg non-IID	0.7567 ± 0.0772	0.8842

Observations :

- ① **IID** : Performance équivalente à la baseline.
- ② **Non-IID** : Baisse de la moyenne et hausse de la variabilité.

Comparaison Globale (Figure 1)




Figure – Comparaison des méthodes (5 seeds).

Tendance robuste : le Non-IID (droite) est plus bas et plus dispersé.

Convergence et Stabilité (Figure 2)




Figure – Dynamique d'apprentissage (Moyenne $\pm$ std).

Le Non-IID converge vers un plateau plus bas avec une incertitude plus large.

Diagnostic 1 : Effet Paired par Seed (Figure 5)





Figure – Effet non-IID à seed fixé.

L'effet n'est pas strictement monotone, mais la tendance reste défavorable.

Diagnostic 2 : Hétérogénéité (Figure 6)



Cause racine :

- En Non-IID, les clients ont des distributions très déséquilibrées.
- Conséquence : Gradients locaux divergents (*client drift*).

Figure – Taux de positifs $P(y = 1)$ par client.

Point technique : BatchNorm et petits clients

Problème :

- En Non-IID, certains clients ont très peu de données.
- BatchNorm (mode train) échoue si un batch a une taille de 1.

Correction appliquée

- 1 **Drop_last conditionnel** si le dernier batch vaut 1.
- 2 **Non-participation** des clients avec $n < 2$ (poids nul).

Choix réaliste : maintient la reproductibilité sans modifier l'architecture.

FedProx : Résultat Négatif

Expérimentation :

- Test avec $\mu \in \{0.01, 0.1\}$.
- 5 seeds par configuration.

Résultat :

- Aucune amélioration mesurable par rapport à FedAvg sur ce setup.

Interprétation :

- Taille du test/dataset réduit la sensibilité aux gains faibles.
- Nécessité probable d'une grille μ plus large ou d'un Non-IID plus sévère.

Noise–Utility : Étude empirique (Figure 3)





Figure – Accuracy test en fonction du bruit σ .

Pas de DP formelle. L'effet du bruit est dominé par l'incertitude du test (pas de décrochage brutal).

Fairness : Métriques et Mitigation (Figure 4)



Résultat :

- Amélioration moyenne des métriques d'équité.
- Mitigation par *Reweighting*.

Interprétation prudente due à la taille des sous-groupes.

Figure – Baseline vs Reweighting ($|SPD|$, DI , $|EOD|$).

Preuve d'intégration

Exécution FedAvg via API Fluke réussie (Logs, Coûts Communication).

Portée du résultat :

- **Valide** : L'outillage et la capacité d'exécution.
- **Ne valide pas** : Une supériorité chiffrée (nécessiterait un alignement strict split/model/preprocessing).

Limites Améliorations :

- *Taille Test (60)* : Variabilité forte → Augmenter les seeds.
- *Privacy* : Passer à la DP formelle (Clipping + Accountant ϵ).

Conclusion :

- ① **IID** reproduit la performance centralisée.
- ② **Non-IID** dégrade performance et stabilité (confirmé par diagnostics).
- ③ Extensions (FedProx, Noise, Fairness, Fluke) traitées avec un cadre rigoureux.

Merci de votre attention.

Questions ?